Documentação de Código
Scraping de Restaurantes no Ifood

Vítor Carvalho Marx Lima

Data Atualização: 15/02/2024

Contents

Introdução 2
Requisitos 2
Descrição das Bibliotecas Utilizadas 2
Estrutura do arquivo Excel de Configurações 3
Fluxo de Código: 3
Conclusão 9

Introdução

Este documento descreve o código Python projetado para realizar scraping de dados de restaurantes listados no site iFood a partir de uma lista de endereços. O objetivo é coletar algumas informações sobre os estabelecimentos, como nome, avaliação, categoria, distância, taxa de entrega, e salvá-las em um arquivo Excel para análise posterior.

Requisitos

1 - Para executar este script, é necessário ter Python instalado, junto com as seguintes bibliotecas não instaladas por padrão:

Playwright, bs4, pandas e datetime.

2 – Um arquivo de configurações iniciais denominado 'enderecos.xlsx', onde algumas configurações essenciais para o funcionamento do script serão fornecidas pelo usuário. Essas configurações serão detalhadas posteriormente.

Descrição das Bibliotecas Utilizadas

Playwright: Automatiza o navegador para interações web.

BeautifulSoup (bs4): Analisa o HTML retornado e facilita a extração de dados.

pandas: Utilizado para criar e manipular DataFrames, facilitando a organização dos dados coletados.

datetime: Fornece funções para manipular datas e horários de maneira flexível.

time: Utilizado para pausas durante a navegação, evitando bloqueios por requisições rápidas demais e evitando possíveis erros de carregamento no script.

os: Auxilia na manipulação de caminhos e arquivos do sistema operacional.

Estrutura do arquivo Excel de Configurações

O script de utiliza um arquivo Excel (enderecos.xlsx) para determinar os endereços dos quais os dados dos restaurantes serão coletados. Este arquivo contém quatro colunas essenciais, descritas abaixo:

1 - Endereço: Contém os endereços completos dos locais a serem pesquisados. Cada linha representa um local específico do qual os dados dos restaurantes serão coletados. Os endereços devem estar completos e formatados corretamente para garantir a precisão da busca no site.

2 - Número: Refere-se ao número do edifício ou estrutura dentro do endereço especificado. Se o endereço não possuir um número específico, deve-se utilizar "s/n" (sem número) nesta coluna. Este detalhe é crucial para a precisão na localização dos restaurantes próximos ao endereço indicado.

3 - Número de Páginas: Indica quantas páginas de resultados devem ser coletadas para cada endereço. Este valor pode ser um número inteiro (1, 2, 3, etc.) para especificar um limite de páginas ou a palavra "todas" para indicar que todas as páginas disponíveis devem ser coletadas. Essa flexibilidade permite um controle mais fino sobre a quantidade de dados coletados, otimizando o tempo de execução do script conforme necessário.

4 - Rodar: Esta coluna determina se o endereço especificado na linha correspondente será incluído ou excluído da coleta de dados. Ela aceita dois valores possíveis: "S" (Sim) e "N" (Não). "S" indica que o script deve coletar dados do endereço especificado, enquanto "N" indica que o endereço deve ser ignorado. Isso permite um controle seletivo sobre quais endereços devem ser processados, facilitando a coleta de dados de locais específicos sem a necessidade de deletar endereços do arquivo Excel.

Fluxo de Código:

O script foi projetado para automatizar a coleta de informações sobre restaurantes a partir do site iFood, utilizando um arquivo Excel com endereços específicos como ponto

de partida. O processo inicia com a leitura deste arquivo, onde o script identifica quais endereços devem ser coletados com base na coluna "Rodar", prosseguindo apenas com aqueles marcados com "S". Em seguida, o script acessa o site do iFood, preenche os campos de endereço e número e confirma a localização para navegar até a seção de restaurantes. Uma vez na página dos restaurantes, ele executa a ação de clicar em "Ver mais" conforme o número de vezes especificado na coluna "Número de Páginas" do arquivo Excel.

Durante a coleta, o script extrai o HTML dos restaurantes listados e destila os dados necessários para compor um DataFrame com as colunas detalhadas acima. Cada coluna armazena informações pertinentes:

1 - data: Registra a data da coleta dos dados no formato dia/mês/ano.

2 - codigo_estabelecimento: A posição numérica do restaurante na sequência de coleta, indicando a ordem em que aparecem na listagem do site para o endereço especificado.

3 - endereco_universidade: O endereço que foi usado para realizar a coleta de dados, conforme informado no arquivo Excel.

4 - nome_restaurante: O nome comercial do restaurante conforme listado no iFood.

5 - categoria: A classificação do tipo de comida ou serviço que o restaurante oferece (por exemplo, Padaria, Salgados, Brasileira, Japonesa, etc.).

6 - horario_coleta: O horário exato em que os dados do restaurante foram coletados pelo script.

7 - status: Indicação se o restaurante estava operando (Aberto) ou não (Fechado) no momento da coleta.

8 - score_estrela: A avaliação média do restaurante em estrelas, onde 5 é a pontuação máxima.

9 - foto: Um indicador que mostra se o restaurante possui uma foto de perfil personalizada ou se usa uma imagem padrão do iFood.

10 - distancia: A distância em quilômetros do restaurante até o endereço usado para a busca.

11 - taxa_entrega: O custo de entrega cobrado pelo restaurante para aquele endereço.

Para lidar com imprevistos, como problemas de conexão ou desempenho do computador, o script está equipado para realizar até três tentativas de coleta por endereço. Se ocorrerem erros durante a execução, o script os registra num arquivo de

texto denominado 'enderecos_com_erros.txt'. Quando a coleta ocorre sem contratempos, o arquivo de texto é marcado com a mensagem "Nenhum erro durante a coleta!", servindo como uma confirmação de que o processo foi concluído com sucesso.

Os dados coletados com sucesso são exportados para um excel com o nome no formato **'ifood_data_%d-%m-%Y--%H-%M.xlsx'**, onde 'd' é o dia, 'm' é o mês, '%Y' é o ano, '%H' a hora e '%M' os minutos, por exemplo: **'ifood_data_15-02-2024--13-23.xlsx'.**

As imagens a seguir mostram o fluxo de acesso e coleta ao site:

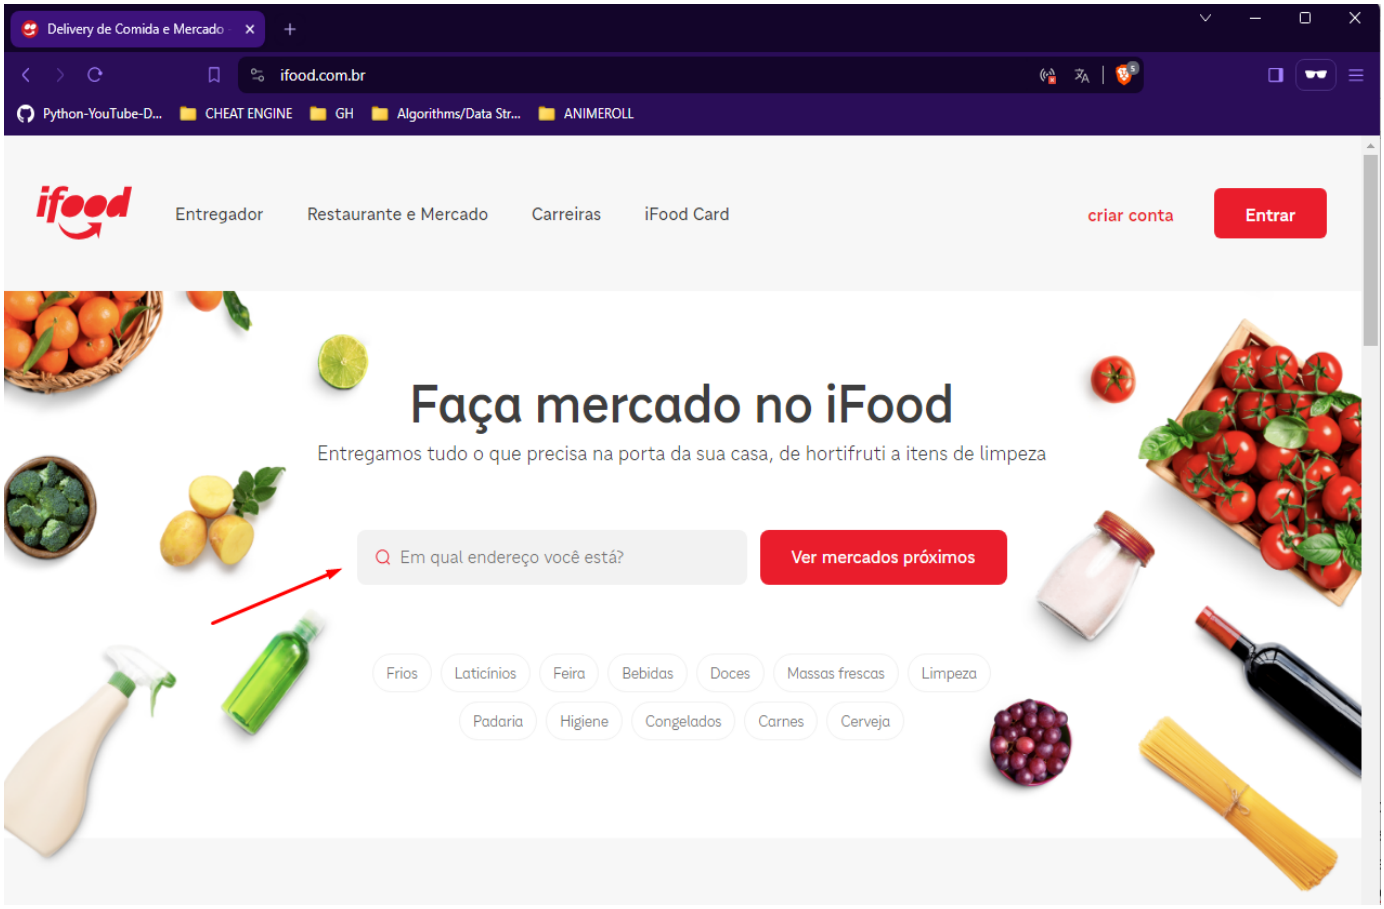

Figura 1: Página inicial 'ifood.com.br', onde o script clicará na barra de pesquisa para inserir o endereço.

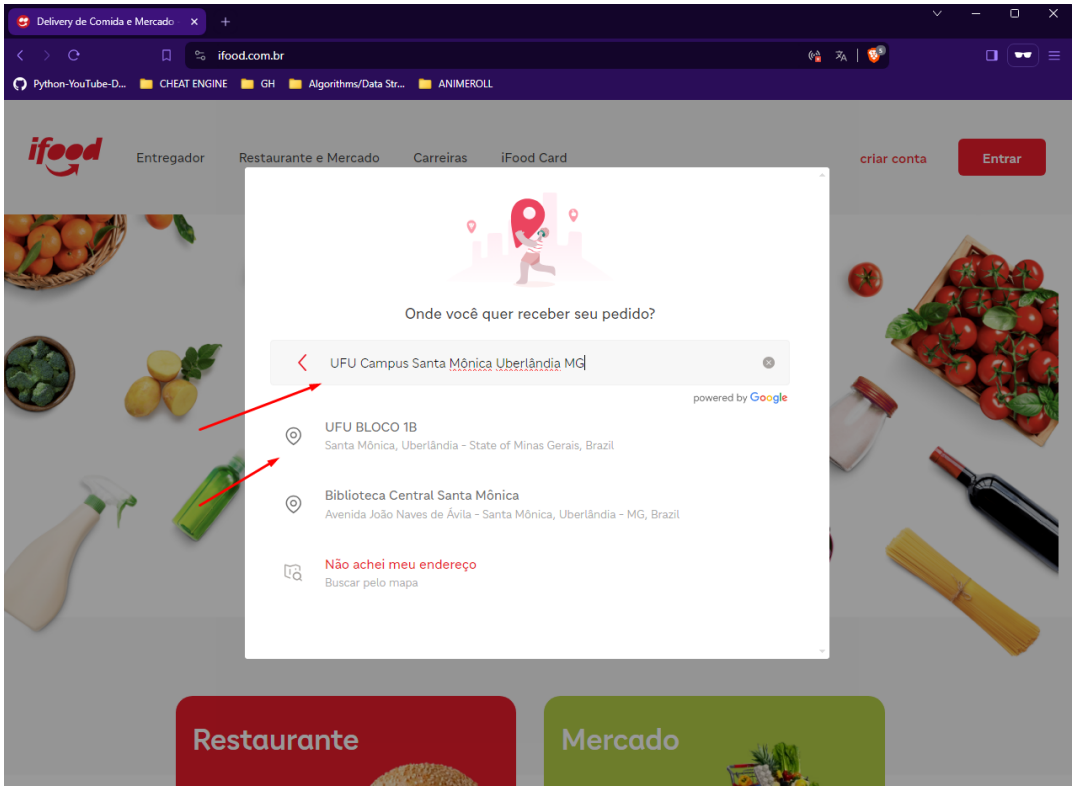

Figura 2: Inserção e seleção do endereço.

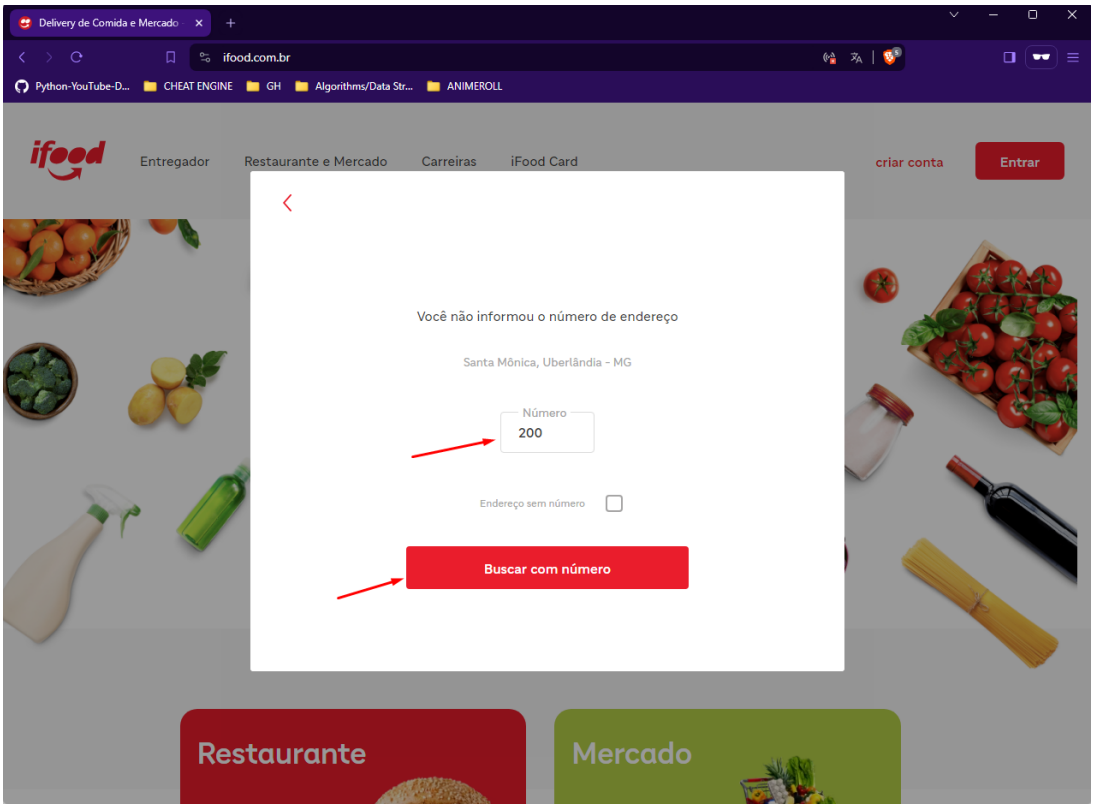

Figura 3: Inserção e confirmação do número.

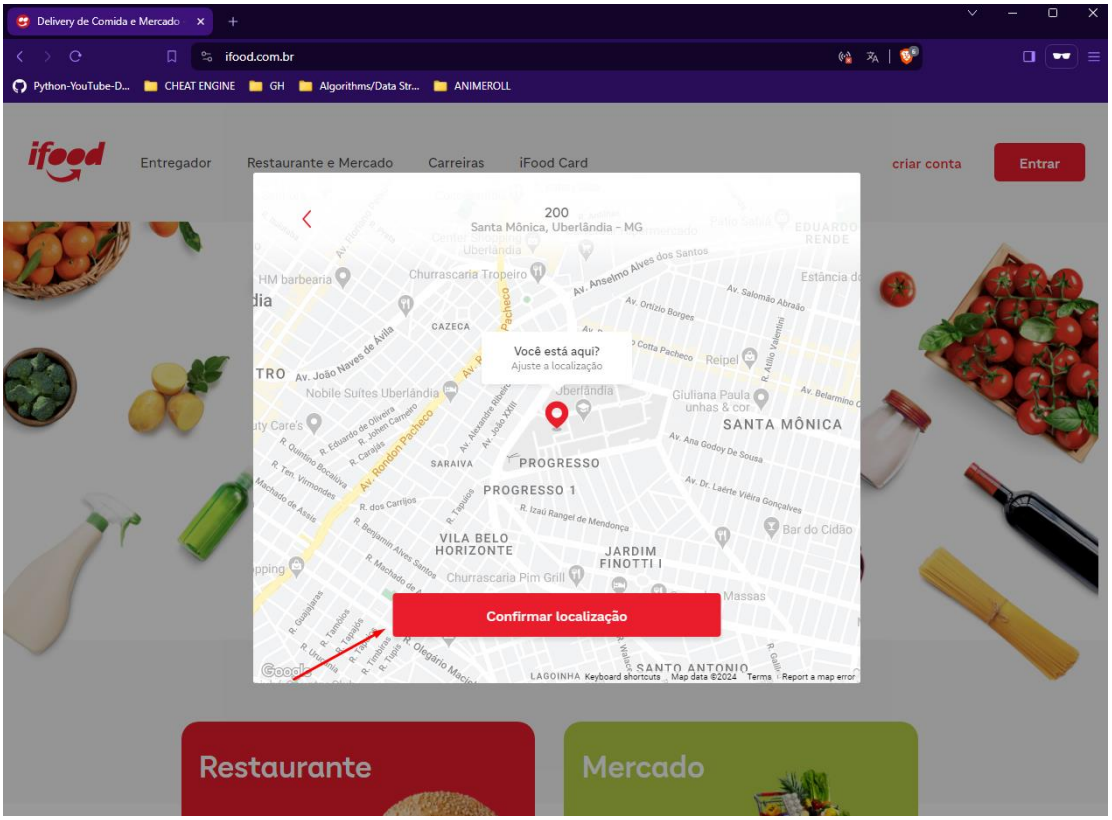

Figura 4: Confirmação da localiação.

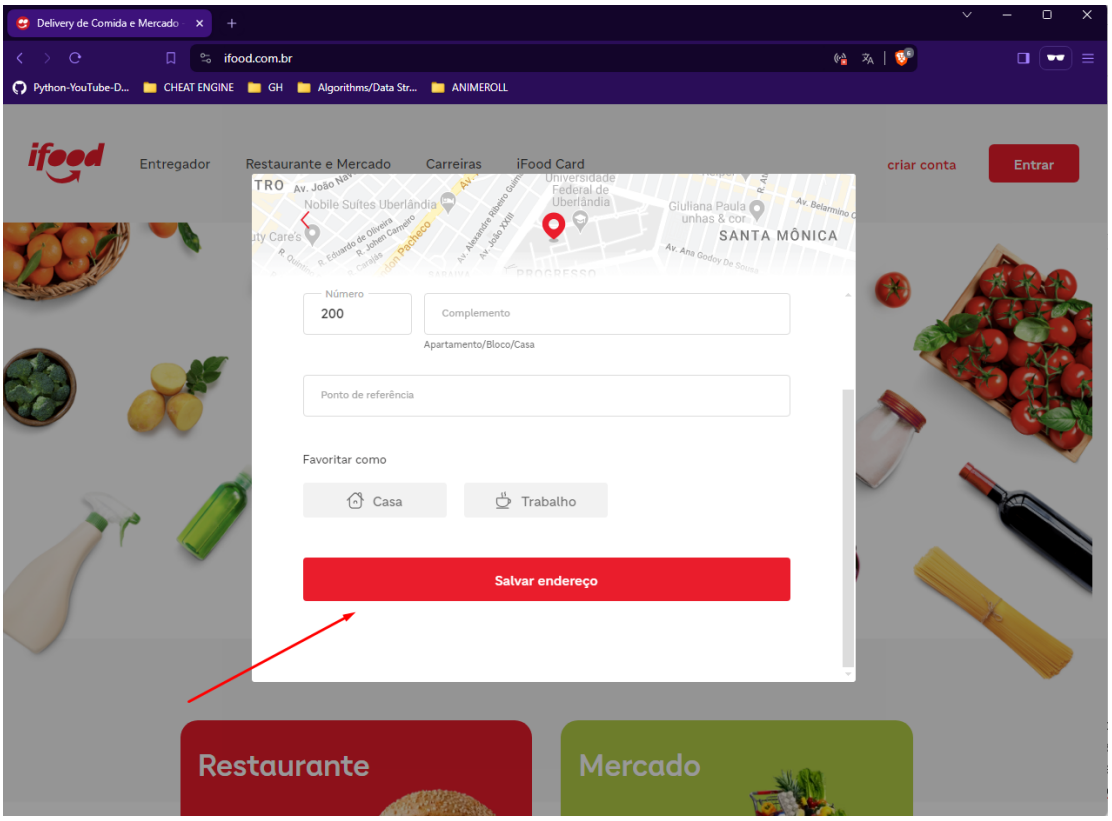

Figura 5: Salvando o endereço fornecido.

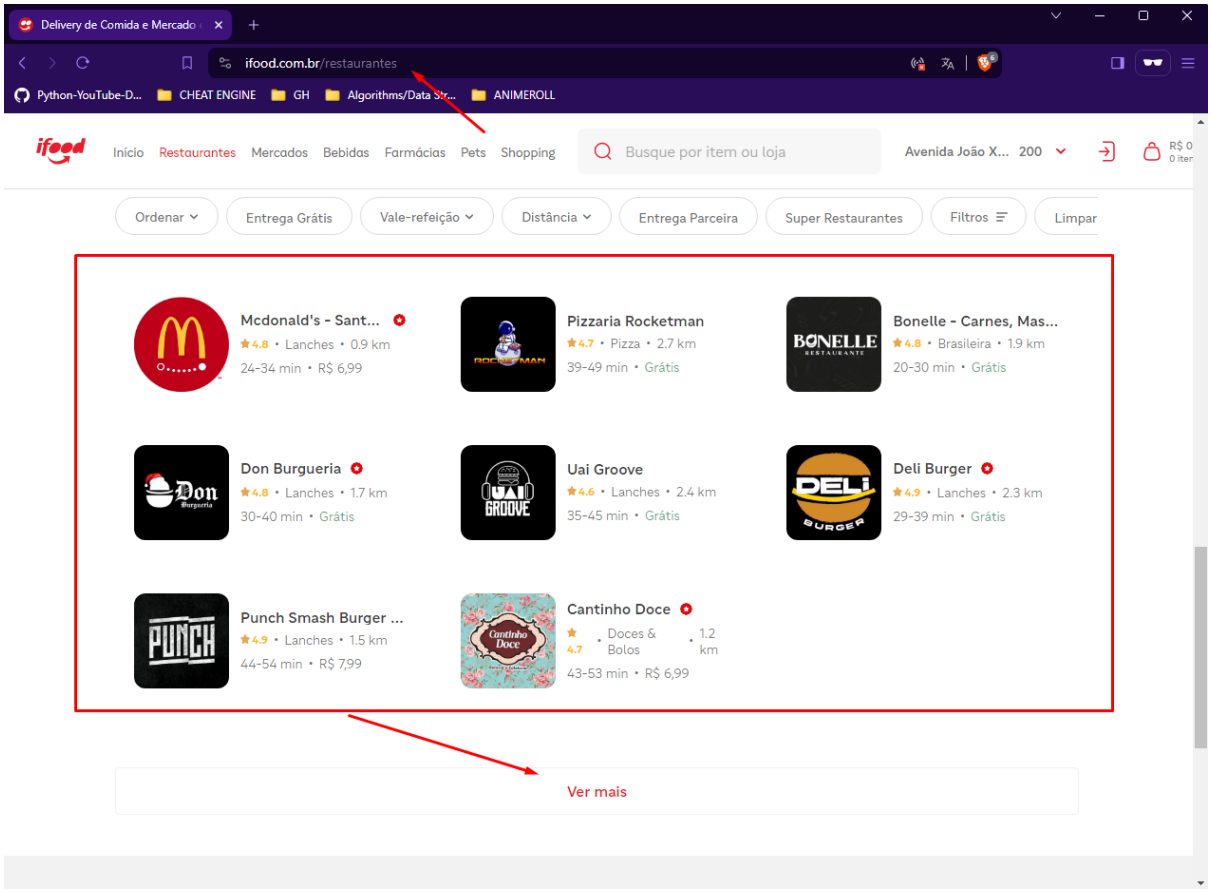

Figura 6: Acesso ao link dos restaurantes, onde Podemos expandir o número de restaurantes que aparecem na página ao clicar em ‘Ver mais’.

Fluxograma

O fluxograma a seguir serve como uma ilustração do funcionamento do script na coleta dos dados.

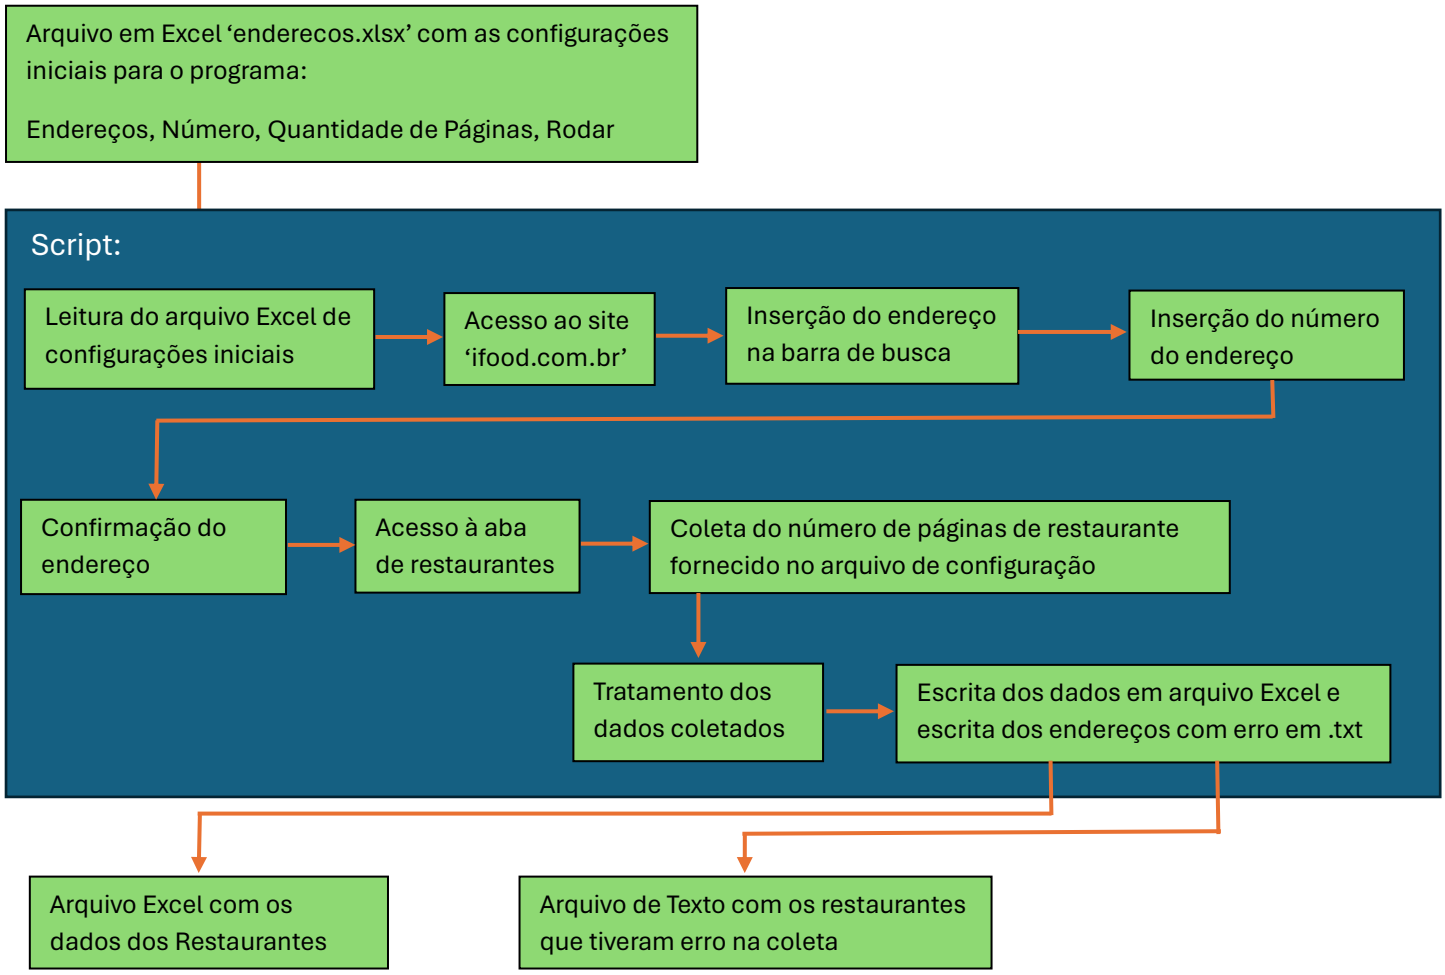

Conclusão

Este script oferece uma solução automatizada para coletar dados de restaurantes no iFood, útil para análises de mercado, avaliação de concorrência, entre outros fins analíticos. A documentação detalha seu funcionamento, requisitos, e estrutura de código, proporcionando um entendimento claro do processo de scraping implementado.